

FileSorter — Classement intelligent des ressources pédagogiques

Tri automatique de documents de cours avec OCR et IA locale (Ollama)

Conception et déploiement d'un outil Python de classement intelligent des ressources pédagogiques, combinant OCR, extraction multi-formats et intelligence artificielle locale (Ollama / Llama 3.1).

DÉPÔT

github.com/sami3737/FileSorter

MODE D'EXÉCUTION

Auto / Interactif

STATUT

Fonctionnel — usage personnel

CONTEXTE & OBJECTIF

Dans le cadre d'un usage personnel et scolaire (BTS SIO), les supports de cours s'accumulent dans un dossier unique sans organisation claire par matière ou par unité. FileSorter automatise ce tri : il surveille un dossier source, lit le contenu réel des documents — texte, tableaux ou images scannées — puis range chaque fichier dans la bonne catégorie sans intervention manuelle systématique.

FONCTIONNEMENT

1 Surveillance

watchdog détecte tout nouveau fichier déposé dans le dossier source, en continu.

2 Extraction

Le texte est extrait selon le format : pdfplumber (PDF), python-docx/openpyxl, ou Tesseract OCR pour les images et scans.

3 Classification

Le contenu est analysé par le modèle Llama 3.1 via Ollama (exécuté en local), avec repli sur des règles de mots-clés et la détection de langue.

4 Apprentissage

Chaque validation ou correction utilisateur est enregistrée dans learning.json et réutilisée pour affiner les classements suivants.

FONCTIONNALITÉS CLÉS

- Surveillance temps réel du dossier source (watchdog)
- Extraction multi-formats : PDF, DOCX, XLSX, ODT, TXT/CSV, images
- OCR sur images et documents scannés (Tesseract)
- Classification par IA locale (Ollama, Llama 3.1)
- Sous-catégories détectées automatiquement (ex. Informatique/U5)
- Mode auto ou interactif avec confirmation utilisateur
- Apprentissage continu à partir des corrections (learning.json)
- Catégories et règles entièrement configurables

STACK TECHNIQUE

Langage	Python 3
IA / LLM	Ollama — Llama 3.1 (local)
OCR	Tesseract OCR
Extraction de texte	pdfplumber, python-docx, openpyxl
Surveillance fichiers	watchdog
Persistance	learning.json (apprentissage)
Configuration	config.py (catégories, chemins, paramètres)

MOTS-CLÉS TECHNIQUES

Python	Ollama	Llama 3.1	Tesseract OCR	Watchdog	pdfplumber	IA générative
Automatisation			Traitement de documents			

Code source et documentation complète disponibles sur GitHub : github.com/sami3737/FileSorter

Projet personnel développé par Sami, dans le cadre du BTS SIO SLAM.